

**PENGEMBANGAN SISTEM PREDIKSI KONSUMSI LISTRIK PADA
GEDUNG MENGGUNAKAN ALGORITMA *MACHINE LEARNING*
(DEVELOPMENT OF ELECTRICITY CONSUMPTION PREDICTION
SYSTEM IN BUILDINGS USING A MACHINE LEARNING
ALGORITHM)**

PROPOSAL TUGAS AKHIR

Disusun sebagai syarat mata kuliah Tugas Akhir

Program Studi S1 Teknik Elektro

Disusun oleh:

ILHAM MAROOF SUTRISNO

1102213052



**Universitas
Telkom**

FAKULTAS TEKNIK ELEKTRO

UNIVERSITAS TELKOM

BANDUNG

2025

**LEMBAR PENGESAHAN
PROPOSAL TUGAS AKHIR**

**SISTEM PREDIKSI KONSUMSI LISTRIK PADA GEDUNG
MENGUNAKAN ALGORITMA *MACHINE LEARNING***

**(ELECTRICITY CONSUMPTION PREDICTION SYSTEM IN
BUILDINGS USING A MACHINE LEARNING ALGORITHM)**

Telah disetujui dan disahkan sebagai Proposal Tugas Akhir

Program Studi Teknik Elektro

Fakultas Teknik Elektro

Universitas Telkom

Disusun oleh:

ILHAM MAROOF SUTRISNO

1102213052

Pembimbing I

Pembimbing II

Desri Kristina Silalahi, S.Si, M.Si

NIP. 20890006

Oon Erixno, S.T., M.Sc., Ph.D.

NIP. 24850003

ABSTRAK

Konsumsi energi pada gedung merupakan sekitar 30% dari total konsumsi energi global dan 26% emisi terkait energi dunia. Karena persentase yang besar, konsumsi energi pada gedung menjadi target utama untuk optimalisasi efisiensi energi. Salah satu cara untuk meningkatkan efisiensi energi untuk suatu gedung adalah mengurangi penggunaan listrik pada *peak hours* dan memaksimalkan penggunaan listrik pada *off peak hours*. Cara ini akan menghemat biaya listrik karena biasanya pada *peak hours* tarif listrik lebih mahal dan sebaliknya untuk *off peak hours*. Penelitian ini berfokus pada prediksi beban listrik jangka pendek pada gedung bertingkat, bertujuan untuk mengurangi pemborosan energi. Dengan menggunakan algoritma *eXtreme Gradient Boosting* (XGBoost), menghasilkan model prediksi dengan tingkat galat Mean Absolute Percentage Error (MAPE) di bawah 15%. Data yang digunakan untuk melatih algoritme adalah konsumsi listrik dari gedung O pada yang berada pada kampus Telkom University dengan pengukuran interval lima menit selama tiga bulan, dan parameter mencakup daya listrik.

Metode penelitian mencakup beberapa langkah utama: pengumpulan data konsumsi listrik menggunakan modul PZEM-004T yang terhubung dengan mikrokontroler ESP32 untuk pengunggahan data secara *real-time* ke platform IoT; pemrosesan data yang meliputi normalisasi, eliminasi *outlier*, dan penyusunan data *time-series*; pelatihan model XGBoost dengan penyesuaian hyperparameter untuk mengoptimalkan akurasi; serta evaluasi model menggunakan metrik akurasi MAPE. Sistem ini juga diuji dalam lingkungan nyata untuk memastikan keandalannya dalam mendukung pengelolaan energi berbasis IoT.

Kata Kunci: *Pembelajaran Mesin, XGBoost, Prediksi Penggunaan Listrik*

DAFTAR ISI

| | |
|--|-----|
| LEMBAR PENGESAHAN PROPOSAL TUGAS AKHIR | ii |
| ABSTRAK..... | iii |
| DAFTAR ISI | iv |
| DAFTAR GAMBAR..... | vi |
| DAFTAR TABEL | vii |
| BAB I PENDAHULUAN | 1 |
| 1.1. Latar Belakang Masalah | 1 |
| 1.2. Rumusan Masalah..... | 3 |
| 1.3. Tujuan | 3 |
| 1.4. Manfaat Hasil Penelitian..... | 4 |
| 1.5. Batasan Masalah | 4 |
| 1.6. Metode Penelitian | 4 |
| 1.7. Jadwal Pelaksanaan..... | 4 |
| BAB II TINJAUAN PUSTAKA | 6 |
| 2.1. Listrik..... | 6 |
| 2.2. Daya Listrik | 6 |
| 2.3. Sistem Prediksi | 7 |
| 2.3.1. Model Prediktif..... | 7 |
| 2.4. Kecerdasan Buatan | 8 |
| 2.4.1. Pengumpulan Data | 9 |
| 2.4.2. Data Kuantitatif | 9 |
| 2.4.3. Data Kontinu | 10 |
| 2.4.4. Transformasi Data | 10 |
| 2.5. Pembelajaran Mesin (ML) | 11 |
| 2.6. XGBoost | 11 |
| 2.6.1. <i>Decision Tree</i> | 12 |
| 2.6.2. <i>Ensemble dan Boosting</i> | 13 |
| 2.7. OpenMeteo..... | 14 |

| | | |
|---------------------------------|--|----|
| 2.8. | <i>Performance Evaluation Metrics</i> | 14 |
| 2.9. | Penelitian Sebelumnya..... | 15 |
| BAB III PERANCANGAN SISTEM..... | | 19 |
| 3.1. | Desain Sistem | 19 |
| 3.1.1. | Sistem Akuisisi Data | 20 |
| 3.1.2. | Sistem Pemrosesan Data dan Ekstraksi Fitur | 21 |
| 3.1.3. | Model Prediksi XGBoost | 21 |
| 3.1.4. | Sistem Evaluasi dan Validasi | 22 |
| 3.2. | Diagram Blok Keseluruhan Sistem..... | 23 |
| 3.2.1. | Fungsi dan Fitur..... | 24 |
| 3.3. | Desain Perangkat Keras | 24 |
| 3.3.1. | Spesifikasi Komponen Perangkat Keras | 25 |
| 3.3.2. | Skematika Perangkat Keras | 28 |
| 3.4. | Desain Perangkat Lunak | 29 |
| 3.4.1. | Flowchart Sistem | 30 |
| 3.4.2. | Dataset | 32 |
| 3.4.3. | Transformasi Data | 32 |
| 3.4.4. | Proses Pelatihan Model | 33 |
| 3.4.5. | Evaluasi dan Visualisasi Hasil | 34 |
| 3.4.6. | Spesifikasi Sub-sistem..... | 34 |
| DAFTAR PUSTAKA | | 40 |

DAFTAR GAMBAR

| | |
|--|----|
| Gambar 2.1 Contoh Hasil Model Prediktif dalam Bentuk Diagram Baris | 8 |
| Gambar 2.2 Taksonomi Kecerdasan Buatan | 9 |
| Gambar 2.3 Representasi Data Kuantitatif dalam Bentuk Diagram Garis | 10 |
| Gambar 2.4 Contoh Decision Tree | 13 |
| Gambar 2.5 Diagram Alur <i>Boosting</i> | 13 |
| Gambar 3.1 Alur Umum Sistem | 19 |
| Gambar 3.2 Desain Tampilan Hasil Prediksi | 20 |
| Gambar 3.3 Diagram Blok Keseluruhan Sistem | 23 |
| Gambar 3.4 Modul PZEM-004T-10A | 26 |
| Gambar 3.5 Modul Microcontroller ESP32-S DEVKIT V1 | 27 |
| Gambar 3.6 Desain Peralat Keras Sistem Logging dan Realtime Data..... | 29 |
| Gambar 3.7 Flowchart Sistem Secara Keseluruhan | 30 |
| Gambar 3.8 Flowchart Subsistem Prediksi..... | 32 |
| Gambar 3.9 Ilustrasi data <i>splitting</i> | 33 |
| Gambar 3.10 Alur Pelatihan Model..... | 34 |

DAFTAR TABEL

| | |
|---|----|
| Tabel 2.1 Penelitian yang Pernah Dilakukan Sebelumnya..... | 15 |
| Tabel 3.1 Tabel Penilaian Komponen KWh Meter | 25 |
| Tabel 3.2 Tabel Penilaian Komponen Mikrokontroler | 27 |

BAB I

PENDAHULUAN

1.1. Latar Belakang Masalah

Konsumsi energi di gedung mewakili bagian signifikan dari penggunaan energi global mencapai sekitar 30% dari total konsumsi energi akhir di seluruh dunia dan 26% dari emisi terkait energi global[1]. Seiring dengan urbanisasi dan perkembangan ekonomi yang terus mendorong pembangunan dan penggunaan gedung, mengoptimalkan efisiensi energi menjadi sangat penting, tidak hanya untuk mengurangi biaya operasional tetapi juga untuk mengurangi dampak lingkungan, terutama emisi gas rumah kaca[2]. Hal ini menekankan pentingnya sistem manajemen energi yang efektif yang dapat meminimalkan pemborosan energi sekaligus memastikan kenyamanan penghuni.

Dalam konteks manajemen energi gedung, dua faktor utama yang mempengaruhi konsumsi energi adalah beban listrik total dan suhu lingkungan. Sistem HVAC, yang sangat dipengaruhi oleh suhu lingkungan, dapat mengonsumsi hingga 30-61% dari total energi listrik gedung[3], [4]. Ketika suhu lingkungan meningkat, sistem pendingin udara memerlukan lebih banyak energi untuk mempertahankan suhu yang nyaman di dalam gedung, menciptakan hubungan yang erat antara kondisi lingkungan dan konsumsi energi total.

Prediksi beban energi telah muncul sebagai alat penting dalam manajemen energi, memungkinkan operator gedung untuk memproyeksikan permintaan energi di masa mendatang berdasarkan data historis, kondisi cuaca, pola hunian, dan faktor relevan lainnya. Prediksi yang akurat membantu mengoptimalkan penjadwalan penggunaan energi, mengurangi biaya permintaan puncak, dan meningkatkan integrasi sumber energi terbarukan[5]. Dengan memperkirakan kebutuhan energi dan mempertimbangkan pengaruh suhu lingkungan secara lebih akurat, gedung dapat menghindari kelebihan beban atau pemanfaatan sistem yang tidak optimal, yang mengarah pada efisiensi energi dan keberlanjutan yang lebih baik.

Perkembangan terbaru dalam analitik data, pembelajaran mesin, dan kecerdasan buatan telah merevolusi peramalan beban energi. Model prediktif, seperti jaringan saraf tiruan dan mesin vektor pendukung, telah menunjukkan janji signifikan dalam meningkatkan akurasi peramalan, terutama di gedung dengan pola penggunaan energi yang dinamis[6]. Model-model ini menganalisis sejumlah besar data untuk menangkap hubungan kompleks dan non-linear antara konsumsi energi, suhu lingkungan, dan parameter lain yang mempengaruhinya, menawarkan prediksi yang lebih andal dibandingkan metode statistik tradisional.

Penelitian ini akan melanjutkan upaya yang dilakukan oleh Juan Yan, Qingsong Chen, Cungang Hu, dan Wenping Cao dalam jurnal mereka di mana dalam jurnal tersebut mereka mengeksplorasi penggunaan XGBoost untuk prediksi beban listrik di masa depan untuk jaringan listrik di Irlandia. Dataset mereka terdiri dari 6 tahun data yang tercatat dari tahun 2014 hingga 2019 dengan pengambilan datanya setiap 15 menit. Makalah ini menggunakan XGBoost dan kombinasi fitur waktu dalam data historis dan fitur deret waktu dalam data deret waktu untuk memprediksi beban jaringan listrik dalam jangka panjang. Hasil kerja keras mereka menghasilkan MAPE yang sangat mengesankan yaitu sebesar 0.02497% [7].

Namun, meskipun penelitian sebelumnya telah memberikan kontribusi signifikan dalam memprediksi beban listrik pada tingkat jaringan, pendekatan yang ada masih memiliki beberapa keterbatasan dalam hal aplikasi skala mikro dan prediksi jangka pendek. Sebagian besar penelitian lebih terfokus pada prediksi jangka panjang untuk jaringan listrik yang lebih besar, yang mungkin tidak sepenuhnya relevan untuk pengelolaan energi pada tingkat bangunan[7]. Selain itu, banyak model prediksi yang ada belum sepenuhnya mengintegrasikan pengaruh fluktuasi suhu lingkungan terhadap konsumsi energi gedung, terutama dalam konteks penggunaan sistem pendingin udara.

Keterbatasan lainnya adalah kurangnya integrasi faktor-faktor yang berhubungan dengan lingkungan gedung secara langsung, seperti tingkat hunian, aktivitas penghuni, dan variasi suhu harian, yang dapat berfluktuasi secara

signifikan dalam periode waktu yang pendek. Prediksi jangka panjang atau berbasis data historis saja tidak cukup untuk menangani kebutuhan energi secara lebih efisien dalam skenario nyata. Selain itu, belum banyak penelitian yang menyarankan penggunaan kombinasi prediksi jangka pendek dan realtime untuk menciptakan sistem manajemen energi yang lebih responsif, yang memungkinkan gedung beradaptasi dengan permintaan energi yang terus berubah[8].

Penelitian penulis bertujuan untuk mengembangkan penelitian sebelumnya dengan mempersempit cakupan pada prediksi jangka pendek yang lebih teroptimasi untuk satu gedung saja, dengan mempertimbangkan baik konsumsi daya maupun pengaruh suhu lingkungan. Berbeda dengan penelitian sebelumnya yang menggunakan dataset nasional, penelitian ini fokus pada tingkat bangunan individu. Dari aspek realtime dan jangka pendek, prediksi yang dihasilkan diharapkan dapat membantu merencanakan pemakaian listrik gedung secara lebih efisien, mengoptimalkan penggunaan sistem pendingin udara berdasarkan perubahan suhu lingkungan, mengurangi lonjakan penggunaan listrik pada waktu tertentu dalam sehari, dan mengoptimalkan biaya penggunaan listrik secara keseluruhan.

1.2. Rumusan Masalah

- 1) Bagaimana mengembangkan model prediksi jangka pendek menggunakan algoritma XGBoost dengan mengintegrasikan variabel konsumsi daya dan suhu lingkungan, dan berapa tingkat akurasi yang dapat dicapai?
- 2) Bagaimana mengoptimalkan parameter algoritma XGBoost untuk mencapai prediksi yang efektif dalam konteks beban listrik dan penggunaan AC gedung?

1.3. Tujuan

Dari latar belakang di atas, masalah yang akan dikaji adalah:

- 1) Untuk mengembangkan model prediksi beban listrik dan penggunaan AC dengan target nilai MAPE kurang dari 10% menggunakan algoritma XGBoost dengan input variabel konsumsi daya dan suhu lingkungan.

- 2) Untuk mengimplementasikan model prediksi yang telah dioptimasi pada sistem manajemen energi gedung dengan mempertimbangkan variabel konsumsi daya dan suhu lingkungan.

1.4. Manfaat Hasil Penelitian

Manfaat yang ingin dicapai dalam penelitian ini adalah:

- 1) Membuat penggunaan listrik gedung lebih efisien.
- 2) Memiliki rencana dalam penggunaan energi listrik dalam jangka pendek.
- 3) Hasil prediksi dapat digunakan untuk pengambilan keputusan mengenai pemakaian perangkat listrik yang lebih baik

1.5. Batasan Masalah

- 1) Data beban listrik akan diambil dari satu gedung.
- 2) Parameter untuk algoritma *forecasting* berupa daya listrik dan suhu ambien.
- 3) Pengambilan data selama dua sampai tiga bulan dengan interval lima menit
- 4) Komputer yang digunakan untuk lokal server menggunakan Ubuntu atau Windows

1.6. Metode Penelitian

Metode penelitian yang dilakukan pada tugas akhir ini adalah:

- 1) Studi literatur untuk mendapatkan pemahaman yang lebih baik tentang keadaan saat ini dan menemukan kelemahan dalam sistem saat ini, tinjau literatur yang ada tentang pembelajaran mesin, metode *forecasting*, dan menampilkan hasil data yang baik.
- 2) Pengambilan data untuk melakukan *training* pada model *deep learning*
- 3) Perancangan model *deep learning* yang digunakan untuk prediksi
- 4) Simulasi untuk menguji kinerjanya
- 5) Implementasi model prediksi dalam gedung

1.7. Jadwal Pelaksanaan

| No | Kegiatan | Tanggal Pelaksanaan |
|----|----------|---------------------|
|----|----------|---------------------|

| | | |
|---|---------------------------|--|
| 1 | Penulisan Bab 1 dan Bab 2 | 16 September – 14 Oktober 2024 (3 Minggu) |
| 2 | Desain Sistem | 21 Oktober – 4 November 2024 (3 Minggu) |
| 3 | Penulisan Bab 3 | 18 November – 23 Desember 2024 (4 Minggu) |
| 4 | Seminar Proposal | 6-7 Januari 2024 (2 Hari) |
| 5 | Pengambilan Data | 17 Februari - 5 Mei 2024 (3 Bulan) |
| 6 | Implementasi Sistem | 6 Mei – 20 Mei 2024 (3 Minggu) |
| 7 | Penulisan Bab 4 dan Bab 5 | 12 Mei- 26 Mei 2024 (3 Minggu) |
| 8 | | |
| 9 | | |

BAB II

TINJAUAN PUSTAKA

2.1. Listrik

Dalam sistem kelistrikan, tegangan adalah gaya yang diperlukan untuk memindahkan elektron. Arus adalah laju aliran muatan per detik melalui material yang diberi tegangan tertentu. Dengan mengambil tegangan dan mengalikannya dengan arus yang terkait, daya dapat ditentukan[9].

Arus listrik adalah aliran listrik itu sendiri dan diukur dalam satuan yang disebut ampere (A). Tegangan adalah kekuatan yang memaksa listrik mengalir dan diukur dalam satuan yang disebut volt (V atau U). Resistansi menyatakan kesulitan aliran listrik dan diukur dalam satuan yang disebut ohm (Ω).

Energi listrik dapat diubah menjadi bentuk energi lain dan digunakan. Sebagai contoh, energi listrik dapat diubah menjadi panas pada pemanas listrik, torsi pada motor, atau cahaya pada lampu neon atau lampu merkuri. Dalam contoh-contoh semacam ini, pekerjaan yang dilakukan listrik dalam periode tertentu (atau energi listrik yang dikeluarkan) disebut sebagai daya listrik. Satuan daya listrik adalah watt (W)[9].

2.2. Daya Listrik

Sejumlah rumus digunakan dalam perhitungan rangkaian listrik, tetapi Hukum Ohm-lah yang menunjukkan hubungan yang paling mendasar: hubungan antara arus listrik, tegangan, dan hambatan. Hukum Ohm menyatakan bahwa arus listrik mengalir secara proporsional terhadap tegangan. Berikut ini adalah rumus untuk menyatakan hubungan antara arus (I) dan tegangan (V)[9].

Nilai daya pada titik waktu tertentu untuk arus bolak-balik dapat diperoleh dengan mengalikan tegangan dan arus untuk titik waktu tersebut.

$$P = V * I \quad (2.1)$$

dimana:

P : Daya aktif (W)

V : Tegangan (V)


I : Arus (A)) : Faktor daya

2.3. Sistem Prediksi

Dalam makalah *Prediction, Judgment, and Complexity: A Theory of Decision-Making and Artificial Intelligence* oleh Agrawal, Gans, dan Goldfarb mendefinisikan prediksi secara luas sebagai kemampuan untuk menggunakan informasi yang diketahui untuk menyimpulkan informasi yang tidak diketahui atau meramalkan hasil di masa depan. Secara umum, prediksi adalah proses menghasilkan wawasan atau perkiraan berdasarkan pola, data historis, atau variabel yang diamati untuk mengantisipasi apa yang mungkin terjadi. Prediksi berfungsi sebagai komponen penting dalam pengambilan keputusan, terutama di bawah ketidakpastian, dengan mengurangi ketidakpastian tentang kondisi dunia di masa depan, sehingga memungkinkan tindakan yang lebih terinformasi dan tepat sasaran[10]. Sistem prediksi memiliki berbagai macam model yang bisa digunakan untuk klasifikasi, peramalan, dan peramalan berdasarkan putusan[11].

2.3.1. Model Prediktif

Model prediktif menggunakan statistika atau data historis yang mencakup fitur-fitur relevan untuk memprediksi hasil di masa depan atau kejadian yang belum diketahui. Keluaran dari model ini sering disajikan dalam bentuk probabilitas, skor, atau label yang mengindikasikan kemungkinan suatu peristiwa terjadi[11]. Salah satu aplikasi model prediktif adalah prediksi beban listrik yang merupakan fokus penelitian ini. Kemudian salah satu hasil dari model prediktif adalah diagram baris pada **Gambar 2.2** yang menunjukkan perbedaan antara data aktual dan data prediktif.




Gambar 2.1 Contoh Hasil Model Prediktif dalam Bentuk Diagram Baris

2.4. Kecerdasan Buatan

Kecerdasan Buatan atau *Artificial Intelligence* (AI) adalah ilmu tentang mengajarkan komputer untuk belajar, bertindak, dan berpikir seperti manusia untuk melakukan tugas dalam kehidupan nyata[12]. Penggunaan kecerdasan buatan sudah menyebar luas dan tidak hanya digunakan pada penelitian tetapi juga pada aplikasi sehari-hari yang biasa. Salah satu contoh kegunaan kecerdasan buatan yang cukup populer adalah algoritma rekomendasi konten yang digunakan oleh YouTube, Spotify, dan sejenisnya. Menurut laporan McKinsey yang berjudul *The state of AI in 2022*, rata-rata penggunaan AI di industri meningkat dua kali lipat dari 20% pada tahun 2017 menjadi 50% pada tahun 2022[13].

Kecerdasan buatan mencakup beragam disiplin ilmu dan aplikasi yang saling terkait. Salah satu cabang utamanya adalah *machine learning* (pembelajaran mesin), yang menjadi fokus penelitian ini. *Machine learning* memungkinkan komputer untuk belajar dari data dan membuat keputusan tanpa diprogram secara eksplisit. Untuk memberikan gambaran yang lebih jelas mengenai hubungan antara

kecerdasan buatan, *machine learning*, dan *deep learning* (pembelajaran mendalam), taksonomi kecerdasan buatan disajikan dalam **Gambar 2.3**.



Gambar 2.2 Taksonomi Kecerdasan Buatan

2.4.1. Pengumpulan Data


Data dapat berasal dari berbagai sumber, seperti basis data internal, kumpulan data publik, API, atau data yang dihasilkan dengan cara yang lain. Data juga tersedia dalam bentuk terstruktur, seperti basis data, dan bentuk tidak terstruktur, seperti teks, gambar, atau aliran waktu nyata. Untuk *supervised learning*, data sering kali diberi label untuk memberikan hasil yang diinginkan, sementara teknik seperti augmentasi data meningkatkan keragaman set data tanpa pengumpulan data baru[14].

Pengumpulan data merupakan hal yang mendasar dalam pengembangan AI, karena model bergantung pada data berkualitas tinggi dan relevan untuk mempelajari pola dan membuat prediksi. Tipe data yang digunakan seperti berikut:

2.4.2. Data Kuantitatif

Data kuantitatif adalah jenis data yang dapat diukur atau diungkapkan dalam bentuk angka. Data ini digunakan untuk mengukur atau menggambarkan jumlah, besaran, atau atribut lain yang dapat diukur secara numerik[15]. Data kuantitatif bisa di representasikan dalam banyak bentuk, misal diagram batang, diagram lingkaran, dan diagram *scatter*. Namun penelitian ini akan digunakan diagram baris karena ia menampilkan perubahan terhadap waktu dan memberikan gambaran

terhadap kecenderungan data, sebab digunakan untuk menampilkan kecenderungan pada penggunaan listrik.



Gambar 2.3 Contoh Representasi Data Kuantitatif dalam Bentuk Diagram Garis [16]

2.4.3. Data Kontinu

Data kontinu merupakan turunan dari tipe data kuantitatif dan dapat direpresentasikan dalam berbagai nilai numerik, seperti bilangan desimal, bulat, dan lain-lain. Beberapa contoh tipe data kontinu adalah tinggi, berat, waktu, suhu, usia. Tipe data yang akan digunakan untuk data time-series yang didapat dari monitoring *power meter* gedung dan akan digunakan untuk pelatihan model pembelajaran mesin XGBoost[17].

2.4.4. Transformasi Data

Dalam konteks ini, transformasi merujuk pada suatu proses perubahan. Pada tahap ini, data yang telah dikumpulkan akan melalui pemrosesan yang dilakukan secara iteratif, yang mencakup persiapan data, konversi ke dalam format yang diperlukan, dan evaluasi untuk mengidentifikasi serta menghapus informasi yang tidak relevan. Persiapan data terdiri dari teknik-teknik yang berkaitan dengan analisis data mentah untuk menghasilkan data berkualitas, yang meliputi integrasi

data, transformasi data, pembersihan data, pengurangan data, dan diskretisasi data. [18]. Dataset yang digunakan akan menjalani proses “pembersihan” dengan cara interpolasi poin data yang tidak ada dan menggantikan point data yang terpercil. Kemudian dataset menjalani proses *resampling* dengan metode SMOTE (*Synthetic Minority Oversampling Technique*), yang membuat data sintetis dengan menginterpolasi sampel yang ada pada kelas minoritas.

2.5. Pembelajaran Mesin (ML)

Pembelajaran mesin atau *machine learning* (ML) adalah proses pemrograman komputer untuk mengoptimalkan kriteria kinerja dengan menggunakan data contoh atau pengalaman masa lalu. Kita memiliki sebuah model yang didefinisikan hingga beberapa parameter, dan pembelajaran merupakan pelaksanaan program komputer untuk mengoptimalkan parameter model tersebut dengan memanfaatkan data pelatihan atau pengalaman sebelumnya. Model ini dapat bersifat prediktif untuk membuat prediksi di masa depan, deskriptif untuk memperoleh pengetahuan dari data, atau keduanya[19].

2.6. XGBoost


XGBoost, atau Extreme Gradient Boosting, adalah kerangka kerja ML yang kuat dan dapat diskalakan yang dirancang khusus untuk peningkatan *tree*[20]. Karakteristik dari XGBoost adalah implementasi dari peningkatan gradien, yang melibatkan konstruksi berurutan dari beberapa *decision tree*. *Decision tree* yang digunakan adalah jenis pohon regresi, di mana setiap node pada pohon membagi data berdasarkan fitur tertentu untuk meminimalkan kesalahan prediksi. XGBoost membangun *decision tree* secara bertahap dalam proses boosting, seperti yang terlihat pada **Gambar 2.4**. Pada setiap iterasi, sebuah *decision tree* baru ditambahkan untuk memperbaiki kesalahan prediksi yang dibuat oleh model sebelumnya. Pohon baru ini dilatih menggunakan data residual, yaitu perbedaan antara prediksi model sebelumnya dan nilai sebenarnya. Proses ini berlangsung hingga jumlah pohon yang diinginkan tercapai atau hingga model mencapai tingkat akurasi tertentu. Hasil akhir prediksi didapatkan dengan menggabungkan kontribusi dari semua *decision tree*, yang masing-masing memiliki bobot berdasarkan pentingnya dalam mengurangi kesalahan prediksi.

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i \hat{y}_i^{(t-1)}) + f_t(x_i) + \Omega(x_i) \quad (2.2)$$

Rumus diatas merupakan rumus utama pada XGBoost yang merupakan gabungan dari fungsi loss Mean Squared Error ($l(y_i \hat{y}_i^{(t-1)})$) yang berfungsi untuk mendapatkan tingkat error antara nilai aktual (y_i) dan nilai prediksi dari iterasi sebelumnya ($\hat{y}_i^{(t-1)}$), fungsi boosting ($f_t(x_i)$) dimana model dilatih berdasarkan weight model sebelumnya, dan term regularisasi ($\Omega(f_t)$) digunakan untuk memberikan penalti pada kompleksitas (f_t).

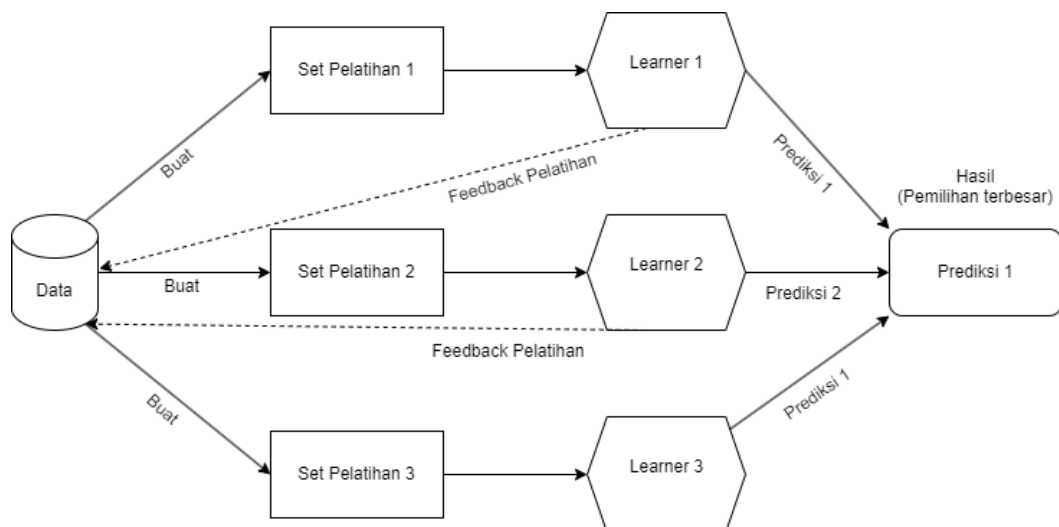
2.6.1. *Decision Tree*

Decision tree adalah salah satu algoritma pembelajaran mesin yang berbasis pada struktur pohon, di mana setiap node internal mewakili atribut atau fitur, cabang mewakili aturan keputusan, dan setiap daun mewakili hasil atau label seperti pada **Gambar 2.4**. Proses ini dimulai dari akar pohon, di mana setiap split bertujuan untuk memaksimalkan pemisahan data sesuai dengan target yang diinginkan. Setelah pembentukan pohon selesai, model ini dapat digunakan untuk prediksi dengan menelusuri jalur dari akar hingga daun berdasarkan nilai atribut input[9]. Hasil akhir berupa jalur terbaik pada *decision tree* yang merupakan visualisasi semua keputusan dan hasilnya.



Gambar 2.4 Contoh Decision Tree

2.6.2. Ensemble dan Boosting



Gambar 2.5 Diagram Alur *Boosting*

Ensemble pada pembelajaran mesin adalah konsep dimana dibuatlah model simpel yang memiliki daya belajar yang rendah (*weak learner*) kemudian hasil dari semua model tersebut digabungkan untuk meningkatkan akurasi dan keandalan hasil. Pada penelitian ini, jenis ensemble yang digunakan adalah boosting, di mana, seperti yang terlihat pada **Gambar 2.5**, proses ini berlangsung secara bertahap. Model pertama dilatih menggunakan data dan *weight* acak, hasil pelatihan model pertama digunakan untuk memperbaiki set pelatihan model kedua dan *weight* yang digunakan sehingga hasilnya lebih baik dibanding model pertama. Proses ini dimana setiap model selanjutnya dibuat dengan saran perbaikan dari model sebelumnya berjalan sampai jumlah model yang diinginkan tercapai. Hasil prediksi dari semua model kemudian dikumpul dan hasil prediksi yang paling banyak dikeluarkan oleh semua model itu menjadi hasil akhir[21].

2.7. OpenMeteo

OpenMeteo merupakan layanan web yang dikembangkan untuk menyediakan akses gratis terhadap data meteorologi, termasuk data historis dan prediksi cuaca. OpenMeteo menyediakan API yang memungkinkan akses ke data historis dan prakiraan suhu dengan resolusi temporal satu jam. API historis memungkinkan pengambilan data suhu hingga beberapa dekade ke belakang, sementara API prakiraan dapat memberikan prediksi suhu hingga 16 hari ke depan. Ketersediaan data historis dan kemampuan peramalan melalui API yang mudah diakses membuat OpenMeteo menjadi sumber data yang berharga untuk aplikasi dan penelitian yang membutuhkan data meteorologi, termasuk untuk pengembangan sistem prediksi beban listrik yang mempertimbangkan faktor suhu lingkungan[22].

2.8. Performance Evaluation Metrics

Performance evaluation metrics adalah sebuah metode yang digunakan untuk mengukur performa dari model ML yang telah dibuat[23]. Penilaian model ML ini diperlukan untuk karena penggunaan algoritma dan parameter yang berbeda dapat menghasilkan performa model yang berbeda. Maka itu diperlukan cara untuk mengevaluasi model ML. Di penelitian ini akan menggunakan evaluasi ML dengan MAPE.

$$MAPE = \frac{1}{n} \sum_{i=1}^n \frac{|A_i - F_i|}{A_i} \quad (2.3)$$

A_i adalah nilai aktual

F_i adalah nilai prediksi

n adalah jumlah observasi yang dilakukan

MAPE (Mean Absolute Percentage Error) adalah salah satu ukuran akurasi peramalan yang paling banyak digunakan karena memiliki keuntungan tidak bergantung pada skala dan mudah diinterpretasikan. MAPE didefinisikan sebagai rata-rata dari *absolute percentage error* (APE), yang dihitung dengan membagi selisih nilai aktual dan peramalan dengan nilai aktual[24].

2.9. Penelitian Sebelumnya

Penelitian sebelumnya yang digunakan sebagai bahan referensi dan perbandingan dengan melihat seberapa efektif metode yang digunakan. Maka penelitian yang digunakan tercantum pada **TABEL 2.1**

Tabel 2.1 Penelitian yang Pernah Dilakukan Sebelumnya

| No. | Judul Penelitian | Penulis | Keterangan | Metode yang digunakan | Hasil Akurasi |
|-----|--|---|---|-----------------------|------------------|
| 1 | Analys And Prediction Of Power Load Patterns Based On Xgboost[7] | Juan Yan, Cungang Hu, Qingsong Chen, Wenping Cao (2024) | Penelitian ini menggunakan XGBoost untuk prediksi beban listrik di masa depan untuk jaringan listrik di Irlandia di mana dataset mereka terdiri dari 6 tahun data yang tercatat dari tahun 2014 hingga 2019 | XGBoost | MAPE: 0.02497 |

| | | | | | |
|---|---|--|---|---|-----------------------------|
| 2 | A Novel Ensemble Learning Model Combined Xgboost With Deep Learning Neural Network For Credit Scoring[25] | Xiaowei Hei, Siqu Li, Xin Tian He, Wenqiang Wang, Xiang Zhang, Bin Wang (2022) | Penelitian ini meningkatkan akurasi dan efisiensi klasifikasi untuk penilaian kredit menggunakan model ensemble yang menggabungkan extreme gradient boosting (XGBoost) dan deep neural network (DNN). | XGBoost-DNN | MAPE: 0,1398 |
| 3 | Prediksi Beban Listrik Menggunakan Metode Support Vector Machine (SVM) Melalui Server-Side[26] | Farid Anwar Hidayat (2023) | Penelitian ini menerapkan Support Vector Machine (SVM) untuk memprediksi beban listrik pada beban listrik Gedung P Telkom University | Support Vector Machine(SVM) | MAPE: 15,308 |
| 4 | Prediksi Beban Listrik Jangka Pendek Berbasis Algoritma Feedforward Backpropagation Dengan Mempertimbangkan Variasi Tipe Hari[27] | Ramadani Dwisatya (2015) | Penelitian ini prediksi beban listrik jangka pendek untuk 3 tipe hari dengan metode Jaringan Syaraf Tiruan (JST) menggunakan algoritma feedforward backpropagation. | Jaringan saraf tiruan Feedforward backpropagation | MAPE pada hari kerja : 0,82 |

| | | | | | |
|---|---|------------------------------|--|--|-----------------|
| 5 | Prediksi Beban Listrik Menggunakan Pendekatan Model Bilstm with Attention Berdasarkan Data Cuaca, Studi Kasus Di Bali[28] | Muhamad Fikry Saputra (2023) | Penelitian ini menyajikan studi kasus di Bali, di mana model Bidirectional LSTM with Attention (BiLSTM with Attention) digunakan untuk prediksi beban listrik berdasarkan data cuaca | Bilinear Long Short Term Memory (BiLSTM) | MAPE: 4,025 |
| 6 | Prediksi Penggunaan Beban Listrik Dengan Menggunakan Metode RBF (Radial Basis Function) Berbasis Website[29] | Wahid Alim Machdita (2021) | Penelitian ini bertujuan untuk memprediksi beban listrik yang akan datang dengan menggunakan algoritma Radial Basis Function (RBF) berbasis yang akan diimplementasikan pada web. | Radial Basis Function (RBF) | MAPE: 0.0510012 |


Penelitian-penelitian yang dilakukan dalam rentang waktu 2015 hingga 2024 menunjukkan implementasi beberapa metodologi, termasuk XGBoost, model hibrida XGBoost-DNN, SVM, Jaringan Syaraf Tiruan (mencakup Feedforward Backpropagation dan BiLSTM), serta RBF. Hasil analisis menunjukkan bahwa pendekatan berbasis XGBoost memberikan performa yang lebih unggul, dibuktikan dengan penelitian Juan Yan et al. (2024) yang mencapai MAPE 0,02497 dan model hibrida XGBoost-DNN dengan MAPE 0,1398. Sementara itu, metode konvensional seperti SVM menunjukkan tingkat kesalahan yang lebih tinggi (MAPE 15,308), sedangkan pendekatan jaringan syaraf seperti BiLSTM dan RBF mendemonstrasikan performa moderat dengan nilai MAPE masing-masing 4,025

dan 0,0510012. Hasil-hasil ini secara konsisten memvalidasi bahwa XGBoost merupakan metode yang paling efektif dan akurat untuk prediksi beban listrik dibandingkan dengan pendekatan pembelajaran mesin lainnya yang telah diteliti.

BAB III


PERANCANGAN SISTEM

3.1. Desain Sistem



Gambar 3.1 Alur Umum Sistem

Sistem ini bertujuan untuk memprediksi konsumsi listrik di masa depan dengan memanfaatkan teknologi Internet of Things (IoT) dan kecerdasan buatan. Sistem ini memberikan pemahaman mendalam tentang tren penggunaan energi untuk pengguna, yang memungkinkan pengambilan keputusan strategis dalam pengelolaan beban listrik pada gedung secara efisien melalui sistem kontrol daring. Sistem ini akan dipasang pada ruang panel pada gedung yang ingin di *monitor*. Kemudian, PC memiliki peran seperti server yaitu untuk proses data konsumsi listrik dan membuat prediksi berdasarkan data tersebut. Alur proses ini divisualisasikan pada **Gambar 3.1**. Hasil prediksi akan ditampilkan dalam bentuk grafik yang bisa dilihat pada platform IoT yang akan digunakan. Visualisasi data yang akan disediakan pada platform IoT ditunjukkan pada **Gambar 3.2** terdiri dari dua representasi grafis yang saling melengkapi. Grafik pertama memperlihatkan komparasi antara penggunaan daya yang terukur (diindikasikan dengan garis biru) dan penggunaan daya hasil prediksi (diindikasikan dengan garis oranye) hingga pukul 18:00 (jam contoh saat ini). Sementara itu, grafik kedua menampilkan prediksi penggunaan daya (diindikasikan dengan garis oranye) untuk periode pascapukul 18:00, mengingat belum tersedianya data penggunaan daya terukur untuk interval waktu tersebut. Kedua grafik ini memfasilitasi analisis komprehensif terhadap akurasi model prediktif yang diimplementasikan.



Gambar 3.2 Desain Tampilan Hasil Prediksi

Pada sisi perangkat keras, sistem berupa modul PZEM-004T untuk mengukur penggunaan daya pada gedung. Data yang dihasilkan oleh PZEM-004T dikumpulkan menggunakan ESP32-S, sebuah mikrokontroler yang memiliki konektivitas Wi-Fi bawaan, memungkinkannya mengunggah data ke server cloud atau database lokal secara real-time.

Pada sisi perangkat lunak, sistem prediksi konsumsi listrik yang dikembangkan terdiri dari beberapa komponen utama yang saling terintegrasi. Sistem ini dirancang untuk mengumpulkan data konsumsi listrik dari gedung, melakukan pemrosesan data, dan menghasilkan prediksi konsumsi listrik jangka pendek dengan menggunakan algoritma XGBoost. Gambaran umum sistem dapat dibagi menjadi beberapa bagian utama:

- Sistem Pengumpulan Data
- Sistem Pemrosesan Data
- Model Prediksi XGBoost
- Sistem Evaluasi dan Validasi

3.1.1. Sistem Akuisisi Data

Sistem pengumpulan data bertanggung jawab untuk memperoleh informasi konsumsi listrik dari perangkat keras secara real-time. Komponen utama dalam tahap ini meliputi modul PZEM-004T, yang digunakan untuk mengukur parameter listrik seperti tegangan, arus, daya aktif, daya reaktif, dan konsumsi energi secara akurat. Selain itu, mikrokontroler ESP32-S berfungsi sebagai penghubung antara modul PZEM-004T dan jaringan internet. Mikrokontroler ini mengambil data dari PZEM-004T melalui komunikasi serial dan mengunggahnya ke *database* lokal.

Dengan konektivitas Wi-Fi, data dapat dikirim secara nirkabel, memastikan sistem bekerja tanpa ketergantungan kabel fisik. Sistem ini juga mencakup pengelolaan penyimpanan sementara (*buffer*) pada ESP32-S untuk mengantisipasi gangguan jaringan yang mungkin terjadi.

3.1.2. Sistem Pemrosesan Data dan Ekstraksi Fitur

Tahap berikutnya adalah sistem pemrosesan data dan ekstraksi fitur, yang melibatkan serangkaian proses untuk mengolah data mentah menjadi fitur-fitur yang siap digunakan oleh model prediksi. Proses ini terbagi menjadi tiga tahap utama:

1. Pra-pemrosesan Data
 - Pembersihan data untuk menghilangkan data yang hilang menggunakan interpolasi
2. Ekstraksi Fitur Temporal
 - Ekstraksi fitur waktu dasar: jam (hour of day), hari dalam minggu (day of week), hari dalam bulan (day of month)
 - Perhitungan fitur lag untuk konsumsi daya
 - Perhitungan fitur rolling untuk konsumsi daya
3. Ekstraksi Fitur Lingkungan
 - Perhitungan fitur lag untuk suhu: nilai 1 jam sebelumnya
 - Perhitungan perubahan suhu (delta temperature): selisih dengan periode sebelumnya
 - Perhitungan rolling mean suhu untuk jendela waktu 3 jam dan 6 jam

Data yang telah melalui proses ekstraksi fitur kemudian disimpan dalam format terstruktur di database. Sistem dirancang untuk dapat melakukan pembaruan fitur secara otomatis seiring dengan masuknya data baru, mendukung pengolahan data real-time yang efisien untuk keperluan prediksi.

3.1.3. Model Prediksi XGBoost

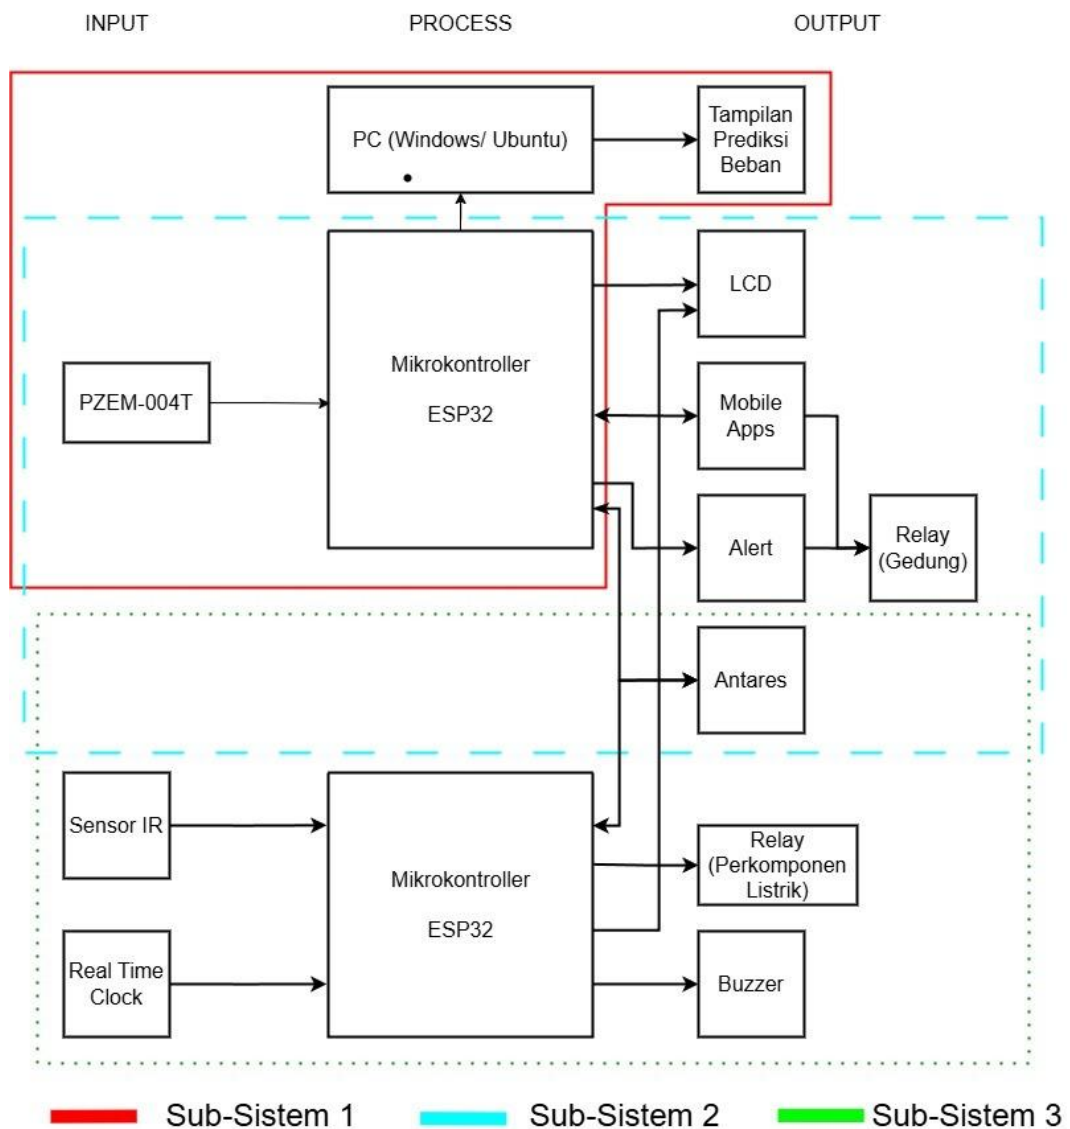
Bagian inti dari sistem ini adalah model prediksi XGBoost, yang digunakan untuk menghasilkan prediksi konsumsi listrik jangka pendek berdasarkan data

historis. XGBoost adalah algoritma pembelajaran mesin berbasis *decision tree* yang dioptimalkan untuk kecepatan dan efisiensi, menjadikannya pilihan ideal untuk menangani dataset yang besar dan kompleks. Model dilatih menggunakan data konsumsi listrik yang dikumpulkan sebelumnya melalui proses yang mencakup pembagian dataset menjadi data pelatihan dan pengujian, pemilihan fitur penting, serta pengaturan hyperparameter. Setelah dilatih, model dapat memprediksi pola konsumsi listrik berdasarkan data real-time yang masuk. Model ini juga diperbarui secara berkala untuk meningkatkan akurasi prediksi dengan menggunakan data terbaru.

3.1.4. Sistem Evaluasi dan Validasi

Sistem evaluasi dan validasi bertanggung jawab untuk memastikan bahwa prediksi yang dihasilkan memiliki tingkat keakuratan yang memadai. Evaluasi dilakukan menggunakan metrik Mean Absolute Percentage Error (MAPE) untuk menilai kinerja model. Selain itu, proses validasi memastikan bahwa data yang digunakan dalam pelatihan dan pengujian bebas dari bias atau kesalahan yang dapat memengaruhi hasil prediksi. Sistem ini juga diuji dalam kondisi nyata untuk mengevaluasi performa prediksi di dunia nyata. Hasil evaluasi dan pengujian kemudian dirangkum dalam laporan yang mencakup tingkat akurasi prediksi serta rekomendasi untuk perbaikan jika diperlukan.

3.2. Diagram Blok Keseluruhan Sistem



Gambar 3.3 Diagram Blok Keseluruhan Sistem

Pada **Gambar 3.3**, ditampilkan blok diagram yang menggambarkan keseluruhan sistem untuk monitoring, prediksi, dan kendali listrik. Dalam penelitian ini, fokus utama peneliti adalah pada sistem monitoring, yang merupakan bagian sub-sistem 1 dalam blok diagram tersebut. Sistem monitoring ini memanfaatkan sensor daya dan mikrokontroler yang sama dengan yang digunakan pada sistem monitoring lainnya untuk pengumpulan data secara real-time dan penyusunan dataset yang digunakan dalam proses pelatihan. Kemudian, juga menggunakan PC yang mempunyai OS (*operating system*) Windows atau Ubuntu.

3.2.1. Fungsi dan Fitur

Fungsi:

- KWh meter: Mengukur keseluruhan penggunaan daya yang digunakan pada gedung.
- Dataset (Pelatihan dan Realtime): Dataset pelatihan yang dikumpulkan selama tiga bulan untuk *training* model XGBoost. Kemudian data realtime adalah data penggunaan daya pada saat itu.
- Model: Digunakan saat prediksi profile penggunaan daya masa depan berdasarkan data realtime.
- Inferensi: Menggunakan model untuk prediksi profile penggunaan daya masa depan.
- Display hasil: Menampilkan grafik hasil prediksi profil penggunaan daya.

Fitur:

- Prediksi jangka panjang dan jangka pendek: Cakrawala waktu yang bisa disesuaikan.
- Tampilan *confidence*: Menunjukkan seberapa yakin model tersebut dalam membuat prediksinya.
- Prediksi multivariabel: memprediksi nilai atau hasil di masa depan berdasarkan beberapa variabel independen (daya, cuaca, dan waktu hari).
- Kepentingan fitur: Menunjukkan pengguna seberapa besar pengaruh pada faktor cuaca dan waktu pada hari pada penggunaan listrik.
- AI yang dapat dijelaskan: Memberikan alasan yang jelas terhadap prediksi. Contoh: “Prediksi penggunaan yang tinggi karena suhu tinggi dan jam sibuk di malam hari.”
- Evaluasi prediksi: Melacak dan menampilkan performa model dari waktu ke waktu untuk memastikan keandalan.

3.3. Desain Perangkat Keras

Dalam perancangan sistem prediksi penggunaan daya untuk masa depan, diperlukan data yang digunakan untuk melatih model XGBoost. Untuk memperoleh dataset yang dibutuhkan dalam melatih dan menggunakan model prediktif tersebut,

diperlukan alat pengukur KWh untuk *log* konsumsi listrik gedung. Kemudian, mikrokontroler digunakan untuk mengunggah data yang telah di *log* ke platform IoT.

3.3.1. Spesifikasi Komponen Perangkat Keras

kWh Meter digunakan untuk mengukur besaran listrik secara *real-time* dan untuk pengumpulan dataset awal. Pada pemilihan kWh meter, faktor utama yang menjadi pertimbangan adalah akurasi pengukuran yang tinggi, serta kemampuan untuk mengukur tegangan AC yang sesuai dengan standar di Indonesia, yaitu 220 VAC. Selain itu, aspek biaya juga menjadi faktor penting, sehingga kWh meter yang dipilih harus memiliki harga yang terjangkau. Berikut ini disajikan tabel penilaian yang digunakan dalam proses pemilihan komponen kWh meter:

Tabel 3.1 Tabel Penilaian Komponen KWh Meter

| Kriteria Seleksi | Bobot (%) | Skor Penilaian (1, 0, -1) | | |
|---|-----------|---------------------------|----------------------|----------------------|
| | | PZEM-004T-10A[30] | Schneider PM5100[31] | SDM120CT [32] |
| Tegangan Ukur | 15% | 80 – 260 VAC | 90 – 450 VAC | 120/230 VAC |
| | | 0 | 0,15 | -0,15 |
| Kelas Akurasi | 40% | 1% | 0,5% | 1% |
| | | 0 | 0,4 | 0 |
| Protokol Komunikasi Yang Bisa Dipakai ESP32 | 15% | UART | RS-485 | RS485 dan MODBUS RTU |
| | | 0,15 | 0 | 0 |
| Harga | 30% | Rp90.000 | Rp4.500.000 | Rp1.125.000 |
| | | 0,3 | -0,3 | 0 |
| Total Nilai | | 0,45 | 0,25 | -0,15 |




Gambar 3.4 Modul PZEM-004T-10A [30]

a. Mikrokontroler

Mikrokontroler digunakan untuk mendapatkan dataset awal *training* model XGBoost. Pada pemilihan mikrokontroler, faktor utama yang menjadi pertimbangan adalah konektivitas nirkabel (WiFi) untuk pengiriman data ke platform IoT, serta jumlah pin GPIO dan UART yang untuk komunikasi dengan kWh meter. Selain itu, biaya juga menjadi faktor penting, sehingga mikrokontroler yang dipilih harus memiliki harga yang terjangkau. Berikut adalah tabel penilaian untuk pemilihan komponen mikrokontroler:

Tabel 3.2 Tabel Penilaian Komponen Mikrokontroller

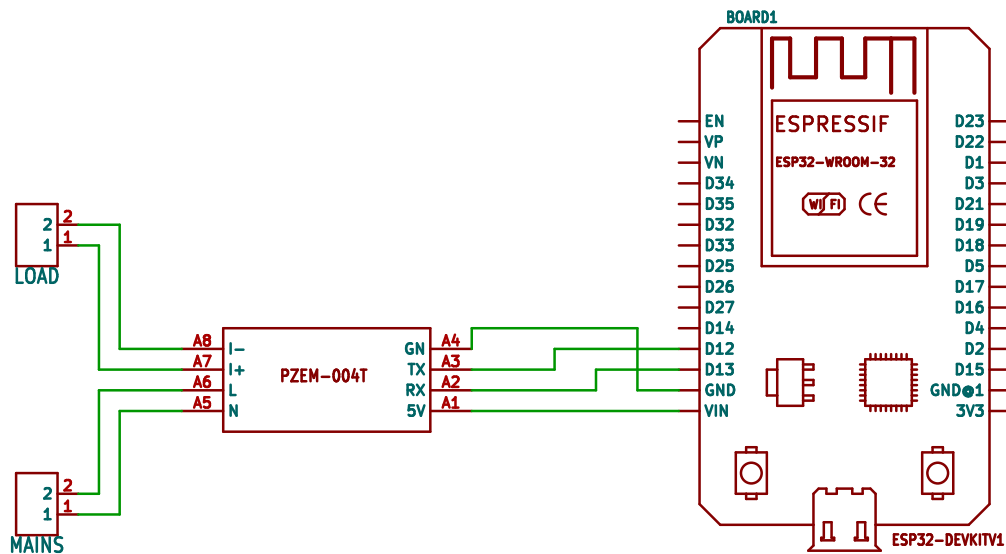
| Kriteria Seleksi | Bobot (%) | Skor Penilaian (1, 0, -1) | | |
|------------------------|-----------|---------------------------|--------------------------|-----------------------|
| | | ESP-32S [33] | Arduino Uno R4 WiFi [34] | Raspbery Pi Pico [35] |
| Tegangan Masukan | 10% | 7-12 VDC | 6-24 VDC | 1,8-5,5 VDC |
| | | 0 | 0,1 | -0,1 |
| Konnektivitas Nirkabel | 25% | WiFi dan Bluetooth | WiFi dan Bluetooth | Tidak ada |
| | | 0,25 | 0,25 | -0,1 |
| Jumlah Pin GPIO | 15% | 25 pin | 14 pin | 23 pin |
| | | 0,15 | -0,15 | 0 |
| Jumlah Perantara UART | 25% | 2 | 1 | 2 |
| | | 0,25 | 0 | 0,25 |
| Harga | 25% | Rp70.000 | Rp300.000 | Rp70.000 |
| | | 0,25 | -0,25 | 0,25 |
| Total Nilai | | 0,9 | 0 | 0,3 |

**Gambar 3.5** Modul Microcontroller ESP32-S DEVKIT V1 [33]

Mikrokontroler ESP-32S mempunyai fitur konektivitas WiFi yang membantu tugas *logging* untuk mendapatkan dataset awal *training* model XGBoost. Data penggunaan daya berasal dari modul PZEM-004T kemudian ESP32-S menerima data melalui protokol serial UART.

3.3.2. Skematika Perangkat Keras

Data ini akan didapatkan menggunakan sensor PZEM-004T yang mengukur daya yang digunakan dan ESP32 untuk mengumpulkan data dari sensor. Rangkaian yang akan digunakan adalah sesuai dengan *blueprint* pada **Gambar 3.4**. Dalam *blueprint*, bagian "MAINS" dan "LOAD" memiliki fungsi penting dalam sistem pengukuran daya listrik. MAINS merupakan sambungan ke sumber listrik utama atau listrik PLN yang masuk ke sistem, yang berupa arus AC 220V/50Hz. Sambungan ini masuk pada bagian input modul PZEM-004T. Sementara itu, LOAD adalah sambungan yang terhubung ke perangkat atau peralatan listrik yang akan diukur konsumsinya, sambungan ini tersambung pada bagian keluaran PZEM-004T. Ketika arus listrik mengalir dari MAINS menuju LOAD, modul PZEM-004T yang terpasang di antara keduanya dapat mengukur parameter listrik konsumsi energi atau daya, ukuran daya yang digunakan oleh PZEM-004T adalah Wh (Watt-hour). Pengukuran ini kemudian dapat diproses oleh mikrokontroler ESP32-S untuk dikirim pada sistem *logging*.

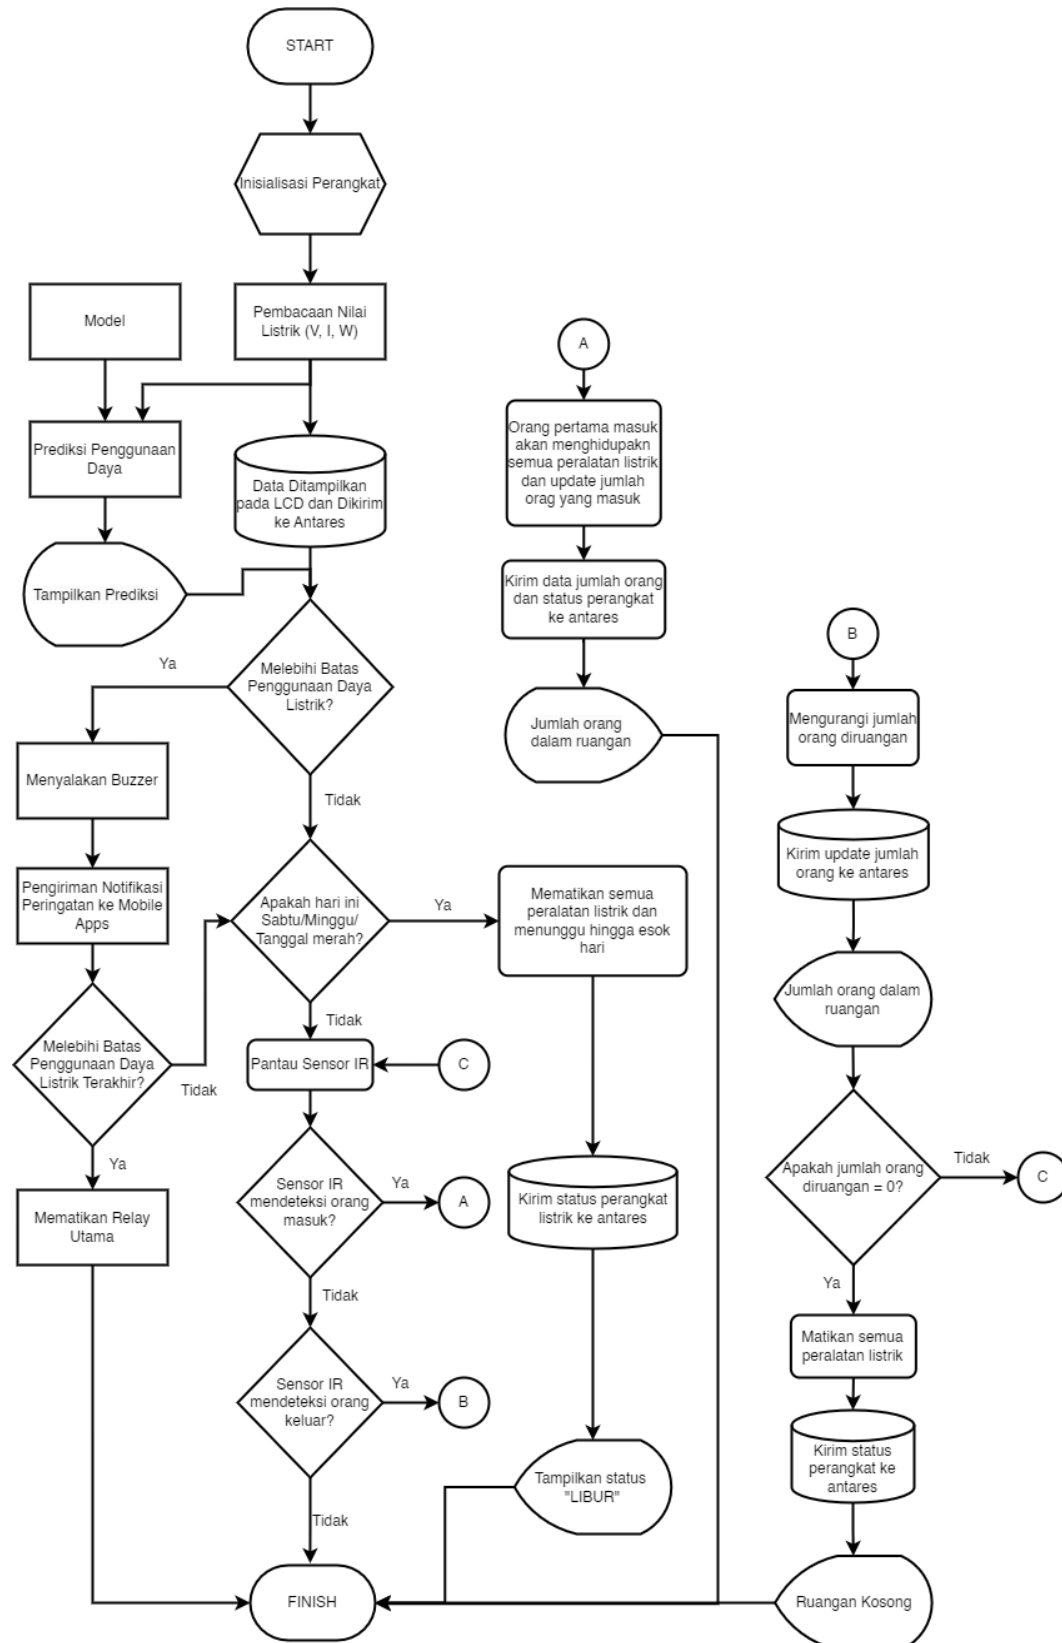


Gambar 3.6 Desain Perangkat Keras Sistem Logging dan Realtime Data

3.4. Desain Perangkat Lunak

Berikut adalah sistem prediksi konsumsi listrik yang dirancang untuk memanfaatkan data historis dan data realtime guna menghasilkan prediksi konsumsi energi yang akurat. Diagram blok di bawah ini menggambarkan alur kerja sistem, mulai dari pengumpulan data hingga penyajian hasil prediksi. Sistem ini terdiri dari tiga komponen utama: input, yang mencakup sumber data; proses, di mana data diolah melalui tahapan training dan inferensi; dan output, yang menampilkan hasil akhir berupa model prediksi dan informasi yang dapat digunakan oleh pengguna. Diagram ini menunjukkan bagaimana data historis digunakan untuk membangun model, sementara data realtime memungkinkan prediksi yang relevan dan berbasis kondisi terkini.

3.4.1. Flowchart Sistem

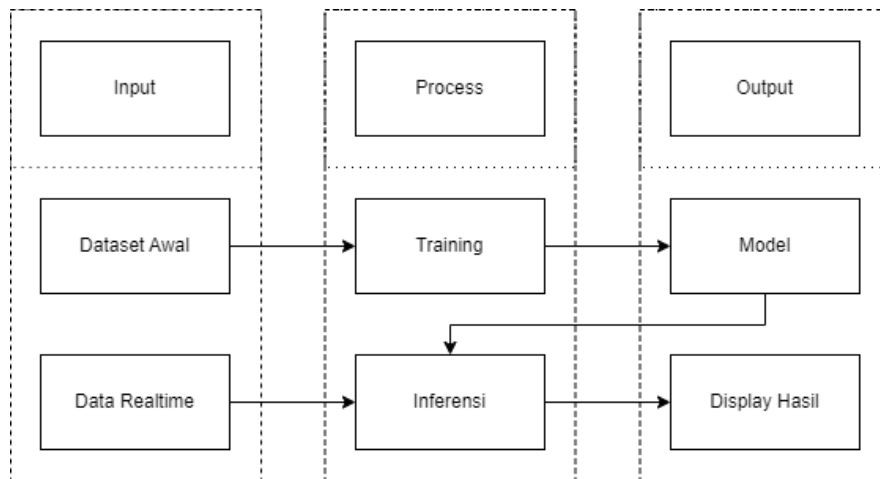


Gambar 3.7 Flowchart Sistem Secara Keseluruhan

Flowchart system pada **Gambar 3.7** menggambarkan sistem manajemen daya listrik secara keseluruhan yang terdiri dari subsistem prediksi, monitoring, dan kontrol. Sistem dimulai dengan inisialisasi perangkat, diikuti oleh pembacaan nilai listrik. Data ini digunakan untuk monitoring dan prediksi penggunaan daya listrik, yang dilakukan oleh model prediktif. Hasil prediksi ini ditampilkan pada platform IoT Antares.

Subsistem monitoring dan kontrol bekerja berdasarkan data aktual dan prediksi. Sensor IR digunakan untuk menghitung jumlah orang yang masuk atau keluar. Berdasarkan data ini, perangkat yang ada di dalam ruangan akan dimatikan jika tidak ada orang pada ruangan. Jika konsumsi listrik melebihi batas, sistem memberikan peringatan melalui buzzer dan notifikasi aplikasi seluler untuk mengambil tindakan segera.

Fokus utama dari prediksi adalah memanfaatkan data real-time dari nilai daya listrik sebagai input ke dalam model, yang kemudian memprediksi proyeksi penggunaan daya. Diagram alir pada **Gambar 3.8** menjelaskan alur sistem prediksi yang terdiri dari tiga komponen utama: input, proses, dan output. Pada bagian input, terdapat dua sumber data, yaitu dataset awal yang digunakan untuk melatih model dan data real-time yang digunakan untuk melakukan prediksi atau inferensi. Bagian proses mencakup dua tahap utama: training, di mana dataset awal diproses untuk menghasilkan model prediksi, dan inferensi, di mana data real-time digunakan untuk menghasilkan output prediksi berdasarkan model yang telah dilatih. Bagian output mencakup hasil akhir dari sistem, yaitu model prediktif yang dapat digunakan secara berkelanjutan dan hasil prediksi yang ditampilkan.



Gambar 3.8 Flowchart Subsistem Prediksi

3.4.2. Dataset


Dataset yang akan digunakan untuk melakukan pelatihan model adalah database yang berupa pengukuran penggunaan daya 3 bulan pada gedung. Label yang digunakan dua yaitu kWh dan suhu luar.

3.4.3. Transformasi Data

Sebelum dataset digunakan untuk melatih model, akan dilakukan beberapa tahap pengolahan data. Tahapan ini adalah data splitting dan data resampling hal ini dilakukan untuk menyiapkan dan memproses data yang ada untuk menghasilkan model yang memiliki performa tinggi. Pada data splitting dilakukan pemisahan data menjadi data training sebagai data latih model dan data testing untuk mengevaluasi model yang telah dibuat. Lalu pada data resampling dilakukan pengambilan ulang data training untuk memastikan kesetaraan jumlah data.

a) Data Splitting

Pada data splitting, dataset akan dipisahkan menjadi 2 bagian yaitu data training dan data testing. Di mana dari jumlah awal data akan dibagi dengan rasio 80% untuk data training dan 20% menjadi data testing.



Gambar 3.9 Ilustrasi data *splitting*

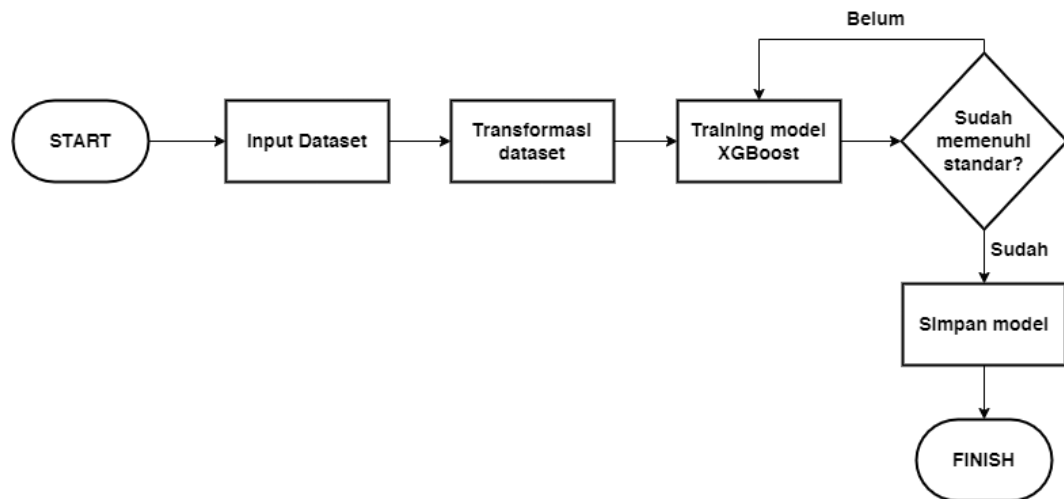
3.4.4. Proses Pelatihan Model

Proses pelatihan melibatkan pengajaran model XGBoost untuk mengenali pola dalam data penggunaan listrik berdasarkan berbagai fitur, seperti penggunaan historis, kondisi cuaca, dan variabel yang berhubungan dengan waktu. Tahap ini hanya berfokus pada pengembangan model dengan menggunakan dataset yang telah diproses sebelumnya.

Pada awalnya, dataset pelatihan, yang terdiri dari 80% dari total data, dimasukkan ke dalam model XGBoost. Selama tahap ini, penyetelan hyperparameter diterapkan untuk mengoptimalkan model. Parameter utama meliputi:

- a) Jumlah *decision tree*: Menentukan berapa banyak *tree* yang dibangun selama pelatihan.
- b) Kedalaman maksimum *tree*: Mengontrol kompleksitas masing-masing *tree* dengan membatasi kedalamannya.
- c) *Learning rate*: Menyeimbangkan *learning rate* model dengan mengontrol kontribusi setiap *tree* terhadap keseluruhan model.

Pelatihan ini melibatkan pembuatan *decision tree* secara berulang, di mana setiap *tree* berikutnya mengoreksi kesalahan dari *tree* sebelumnya. XGBoost menggunakan *gradient boosting* untuk meminimalkan fungsi *loss* dan meningkatkan akurasi prediksi model dari waktu ke waktu. Standar pada gambar bermaksud nilai MAPE yang berada di bawah 5.



Gambar 3.10 Alur Pelatihan Model

3.4.5. Evaluasi dan Visualisasi Hasil

Untuk mendapatkan model dengan performansi terbaik, diperlukan parameter uji atau evaluasi hasil pelatihan untuk dapat menilai tingkat performansi suatu model. Pada penelitian ini akan digunakan metrik MAPE (Mean Absolute Percentage Error) untuk menilai akurasi prediksi. Jika performa model tidak memenuhi standar yang dibutuhkan, penyesuaian dilakukan pada hyperparameter, dan proses pelatihan diulang. Model akhir, yang memenuhi kriteria kinerja, kemudian disimpan untuk digunakan dalam tahap prediksi atau inferensi.

3.4.6. Spesifikasi Sub-sistem

A) Sub-Sistem Input

1. Fungsi : Membaca data penggunaan daya (kWh) dari modul PZEM-004T
2. Spesifikasi : Protokol yang digunakan untuk komunikasi adalah UART, ESP-32S sebagai perantara untuk modul PZEM-004T dan sistem *logging*

B) Sub-Sistem Pemrosesan Data

1. Fungsi : Prediksi penggunaan listrik berdasarkan data historis, cuaca, dan fitur waktu menggunakan model XGBoost
2. Algoritma : Membangun *decision tree* berulang untuk mengurangi residu, menciptakan ansambel yang menangkap pola kompleks

C) Sub-Sistem Output

1. Fungsi : Menampilkan hasil prediksi pada grafik

2. Spesifikasi : Platform IoT yang digunakan

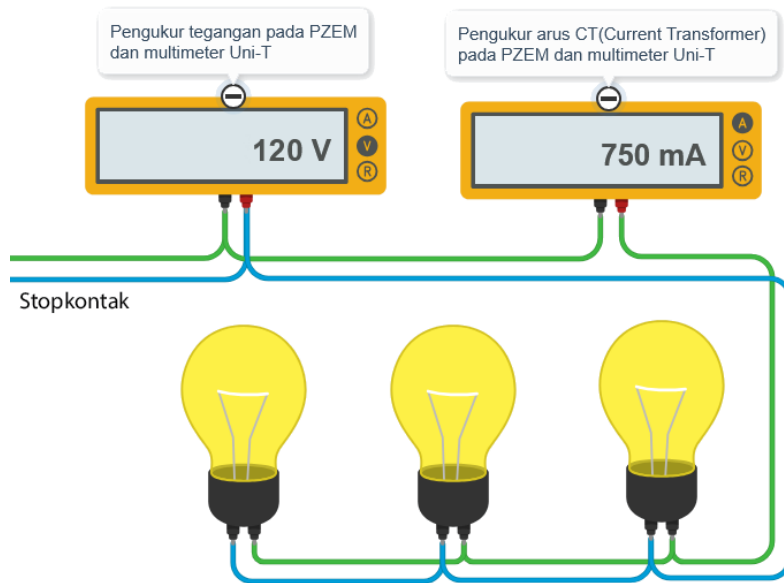
BAB IV

HASIL DAN ANALISIS


Pada bab ini akan dilakukan pemaparan pengujian dan kalibrasi sensor pada sistem yang dibuat kemudian hasil dan analisa kerja sistem secara keseluruhan. Percobaan ini bertujuan untuk mengevaluasi kemampuan sistem untuk mengoptimalkan penggunaan energi listrik, khususnya dalam hal mengoptimalkan penggunaan energi listrik melalui penyediaan estimasi konsumsi listrik yang akurat kepada pengguna.

4.1. Pengujian dan Kalibrasi Sensor (PZEM-004T)

Sensor PZEM-004T digunakan untuk mendapat nilai penggunaan daya yang didapat melalui nilai tegangan dan arus. Untuk memastikan bahwa daya akurat, maka nilai tegangan dan arus dari sensor PZEM harus akurat terlebih dahulu. Untuk memastikan bahwa sensor yang digunakan akurat maka perlu dilakukan pengujian dan kalibrasi sensor. Pengujian dilakukan untuk mendapat data keluaran arus dan tegangan, menggunakan data tersebut keluaran pada sensor disesuaikan (kalibrasi). Alat pengukur tegangan dan arus yang menjadi acuan adalah *clamp meter* digital UNI-T UT202A+. Berikut adalah visualisasi rangkaian pengujian dan realisasinya:



Gambar 4.1 Skematik Rangkaian Penguji



Gambar 4.2 Realisasi Rangkaian Penguji

Data dikumpulkan dengan beban yang bervariasi untuk menilai respon sensor terhadap variasi tegangan dan arus. Untuk pendapatkan data sensor saat pengujian dilakukan secara manual dengan melihat nilai keluaran PZEM melalui serial monitor. Karena sensor PZEM menggunakan komunikasi serial untuk pengiriman data maka ESP digunakan sebagai perantara antara sensor dan Arduino IDE pada laptop. Kemudian, pendapatkan nilai acuan dari clamp meter dilakukan secara manual pula dengan melihat langsung layar clamp meter. Data yang

diperoleh selama pengujian kemudian dianalisis untuk menentukan perbedaan antara nilai yang diukur oleh sensor PZEM dan nilai acuan clamp meter. Kedua tabel berikut adalah hasil rata-rata dari pengukuran tegangan dan arus pada lima beban dengan setiap beban dicatat datanya sebanyak tiga puluh kali pada interval waktu dua puluh detik:

Tabel 4.1 Hasil Pengujian Tegangan

| No. | Beban | Nilai Sensor | Nilai Acuan | Simpangan | Persentase Error | Persentase Akurasi |
|-----|--------------------------------|--------------|-------------|-----------|------------------|--------------------|
| 1 | Lampu LED 8 Watt | 215,603 | 215,610 | 0,120 | 0,056 | 99,944 |
| 2 | Lampu LED 12 Watt x3 (36 Watt) | 212,987 | 213,063 | 0,163 | 0,077 | 99,923 |
| 3 | Panci Listrik 150 Watt | 206,350 | 205,663 | 0,720 | 0,077 | 99,650 |
| 4 | Dispenser 300 Watt | 207,687 | 206,890 | 0,797 | 0,385 | 99,615 |
| 5 | Panci Listrik 600 Watt | 206,323 | 204,707 | 1,623 | 0,793 | 99,207 |

Tabel 4.2 Hasil Pengujian Arus

| No. | Beban | Nilai Sensor | Nilai Acuan | Simpangan | Persentase Error | Persentase Akurasi |
|-----|--------------------------------|--------------|-------------|-----------|------------------|--------------------|
| 1 | Lampu LED 8 Watt | 0,047 | 0,040 | 0,006 | 15,454 | 84,546 |
| 2 | Lampu LED 12 Watt x3 (36 Watt) | 0,228 | 0,183 | 0,045 | 24,475 | 75,525 |
| 3 | Panci Listrik 150 Watt | 1,025 | 1,479 | 0,453 | 30,656 | 69,344 |

| | | | | | | |
|---|------------------------|-------|-------|-------|--------|--------|
| 4 | Dispenser 300 Watt | 1,422 | 1,294 | 0,128 | 10,124 | 89,876 |
| 5 | Panci Listrik 600 Watt | 2,800 | 2,852 | 0,064 | 2,227 | 97,773 |

Sensor PZEM memiliki akurasi pengukuran tegangan yang baik, namun akurasi berkurang ketika mengukur arus. Data pengujian menunjukkan relasi tingkat akurasi yang tidak linier terhadap besarnya arus. Pengukuran yang memiliki akurasi terendah bukanlah beban dengan penggunaan daya terendah tetapi beban 150w yang penggunaan dayanya menengah sedangkan tingkat akurasi tertinggi adalah beban dengan penggunaan daya yang tertinggi.

DAFTAR PUSTAKA

- [1] IEA, “Tracking Clean Energy Progress 2023,” Paris, 2023.
- [2] UNEP, “Annual Report 2023.”
- [3] A. Imran, “An Analysis of Energy Consumption In The Goverment Buildings’ In Indonesian Border,” *Indonesian Journal of Social Technology*, vol. 5, no. 3, 2024, [Online]. Available: <http://jist.publikasiindonesia.id/>
- [4] Dwiarti Larasputri and Maria Anityasari, “Need Analysis for Air Conditioners in Public Sector of Surabaya City Government,” 2016.
- [5] R. Teixeira, A. Cerveira, E. J. S. Pires, and J. Baptista, “Advancing Renewable Energy Forecasting: A Comprehensive Review of Renewable Energy Forecasting Methods,” Jul. 01, 2024, *Multidisciplinary Digital Publishing Institute (MDPI)*. doi: 10.3390/en17143480.
- [6] Mrs. Swati Patil, Dr. Mukund Kulkarni, and Ms Swati Anil Patil, “Energy Load Forecasting Based on the Load Consumption Factors and Techniques Employed: A Review,” *International Research Journal on Advanced Engineering Hub (IRJAEH)*, vol. 2, no. 04, pp. 1028–1036, Apr. 2024, doi: 10.47392/irjaeh.2024.0143.
- [7] J. Yan, Q. Chen, C. Hu, and W. Cao, “Analysis and Prediction of Power Load Patterns based on XGBoost,” in *Proceedings of 2024 IEEE 7th International Electrical and Energy Conference, CIEEC 2024*, Institute of Electrical and Electronics Engineers Inc., 2024, pp. 3078–3083. doi: 10.1109/CIEEC60922.2024.10583054.
- [8] D. Mariano-Hernández, L. Hernández-Callejo, F. S. García, O. Duque-Perez, and A. L. Zorita-Lamadrid, “A review of energy consumption forecasting in smart buildings: Methods, input variables, forecasting horizon and metrics,” Dec. 01, 2020, *MDPI AG*. doi: 10.3390/app10238323.
- [9] Yokogawa Electric Corporation, “Fundamentals of Electric Power Measurements,” 2020.

- [10] Ajay. Agrawal, Joshua. Gans, and Avi. Goldfarb, *The economics of artificial intelligence : an agenda*. The University of Chicago Press, 2019.
- [11] S. Vartak, "An Overview of Predictive Analysis: Techniques and Applications," *Int J Res Appl Sci Eng Technol*, vol. 8, no. 11, pp. 652–662, Nov. 2020, doi: 10.22214/ijraset.2020.32250.
- [12] W. Ertel, "Undergraduate Topics in Computer Science Introduction to Artificial Intelligence." [Online]. Available: <http://www.springer.com/series/7592>
- [13] Michael Chui, Bryce Hall, Helen Mayhew, AlexSingla, and Alex Sukharevsky, "The state of AI in 2022-and a half decade in review," 2022.
- [14] Jason Brownlee, "Data Preparation for Machine Learning," 2020.
- [15] O. Risdiana Chandra Dhewy STKIP PGRI Sidoarjo, "PELATIHAN ANALISIS DATA KUANTITATIF UNTUK PENULISAN KARYA ILMIAH MAHASISWA," *Jurnal Pengabdian Kepada Masyarakat*, vol. 2, no. 3, 2022, [Online]. Available: <http://bajangjournal.com/index.php/J-ABDI>
- [16] A. Pal, "QUANTITATIVE DATA ANALYSIS AND REPRESENTATION," Mar. 2017.
- [17] R. H. Shumway and D. S. Stoffer, *Time Series Analysis and Its Applications*. in Springer Texts in Statistics. New York, NY: Springer New York, 2011. doi: 10.1007/978-1-4419-7865-3.
- [18] S. Zhang, C. Zhang, and Q. Yang, "Data preparation for data mining," *Applied Artificial Intelligence*, vol. 17, no. 5–6, pp. 375–381, May 2003, doi: 10.1080/713827180.
- [19] Ethem Alpaydin, *Introduction to Machine Learning*, Fourth Edition. MIT Press, 2020.

- [20] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, Association for Computing Machinery, Aug. 2016, pp. 785–794. doi: 10.1145/2939672.2939785.
- [21] M. A. Ganaie, M. Hu, A. K. Malik, M. Tanveer, and P. N. Suganthan, “Ensemble deep learning: A review,” Apr. 2021, doi: 10.1016/j.engappai.2022.105151.
- [22] S. Kozanis, A. Christofides, N. Mamassis, and D. Koutsoyiannis, “openmeteo.org: A Web Service for the Dissemination of Free Meteorological Data,” 2013, pp. 203–208. doi: 10.1007/978-3-642-29172-2_29.
- [23] M. Vakili, M. Ghamsari, and M. Rezaei, “Performance Analysis and Comparison of Machine and Deep Learning Algorithms for IoT Data Classification,” 2020, doi: 10.48550/arXiv.2001.09636.
- [24] S. Kim and H. Kim, “A new metric of absolute percentage error for intermittent demand forecasts,” *Int J Forecast*, vol. 32, no. 3, pp. 669–679, Jul. 2016, doi: 10.1016/j.ijforecast.2015.12.003.
- [25] X. He, S. Li, X. T. He, W. Wang, X. Zhang, and B. Wang, “A Novel Ensemble Learning Model Combined XGBoost With Deep Neural Network for Credit Scoring,” *Journal of Information Technology Research*, vol. 15, no. 1, pp. 1–18, Aug. 2022, doi: 10.4018/jitr.299924.
- [26] Farid Anwar Hidayat, “Prediksi Beban Listrik Menggunakan Metode Support Vector Machine (SVM) Melalui Server-Side,” pp. 33–33, 2023.
- [27] Ramadani Dwisatya, “Prediksi Beban Listrik Jangka Pendek Berbasis Algoritma Feedforward Backpropagation Dengn Mempertimbangkan Variasi Tipe Hari,” 2015.

- [28] Muhammad Fikry Saputra, “Prediksi Beban Listrik Menggunakan Pendekatan Model Bilstm With Attention Berdasarkan Data Cuaca, Studi Kasus Di Bali,” 2023.
- [29] Wahid Alim Machdita, “Prediksi Penggunaan Beban Listrik Dengan Menggunakan Metode RBF (Radial Basis Function) Berbasis Website,” 2021.
- [30] “PZEM-004T V3.0 Datasheet.” Accessed: Dec. 17, 2024. [Online]. Available: <https://github.com/vortigont/pzem-edl/blob/main/docs/PZEM-004T-V3.0-Datasheet-User-Manual.pdf>
- [31] “PM5100 Specifiactions.” Accessed: Dec. 25, 2024. [Online]. Available: https://www.se.com/id/id/product/download-pdf/METSEPM5100?filename=Schneider+Electric_PowerLogic-PM5000-Power-Meters_METSEPM5100.pdf
- [32] “SMD120CT Speciifcations”, Accessed: Dec. 25, 2024. [Online]. Available: <http://downloads.spwales.com/spdea120ct-summary-sheet.pdf>
- [33] “ESP32 - DEVKIT V1 Specifications.” Accessed: Dec. 24, 2024. [Online]. Available: <https://grobotronics.com/esp32-development-board-devkit-v1.html?sl=en>
- [34] “Arduino Uno R4 WiFi Specifications.” Accessed: Dec. 25, 2024. [Online]. Available: <https://docs.arduino.cc/resources/datasheets/ABX00087-datasheet.pdf>
- [35] “Raspberry Pi Pico Specifications.” Accessed: Dec. 25, 2024. [Online]. Available: <https://datasheets.raspberrypi.com/pico/pico-datasheet.pdf>

